

最小可用 Agent Runtime - 第一版

Python + DeepSeek | 重点内容预览

目标与边界

从零实现 Agent 主循环，不使用 LangGraph、OpenHands 等 Agent 框架。第一版优先保证循环、工具、会话、记忆、上下文、异常与可测试性完整闭环；暂不实现多 Agent、复杂权限、多渠道和异步定时任务。

组成	第一版实现	关键取舍
Agent Loop	输入 -> LLM -> 工具 -> LLM/回答	最多 5 轮，避免无限调用
工具	calculator / mock search / todo	Schema 注册，LLM 自主决策
Session	(user_id, session_id) 独立历史与待办	同用户窗口不串台
Memory	user_id 级长期偏好	仅“记住...”写入，Top K 召回
Context	记忆 + 摘要 + 最近消息	长历史做基础确定性压缩
可观测性	每次 LLM 与工具写 trace	工具异常转成结果继续对话

数据与记忆隔离

Session Context 仅保留当前聊天窗口的对话、工具调用与摘要。User Memory 按 user_id 存储稳定偏好、长期目标等可复用信息；当前用户指令始终优先。用户 A 的 session-1 写入“偏好 Java 示例”后，session-2 可以召回；用户 B 无法查询到。

测试思路

使用 FakeClient 模拟模型回复，测试不依赖 API：① 模型发起 calculator 调用并根据结果回答；② 不存在工具或参数错误会记录错误且 loop 可继续；③ 两个 session 的待办、消息隔离；④ 同用户跨 session 的长期记忆召回与跨用户隔离；⑤ 连续工具调用触发最大轮次；⑥ 多轮历史触发摘要压缩。

DeepSeek 接入

使用 OpenAI-compatible /chat/completions 与 function calling。API Key、Base URL、Model 均放入 .env；测试和本地演示可先使用 FakeClient，真实演示时替换为 DeepSeekClient。